

Universidad Peruana de Ciencias Aplicadas



Práctica Calificada 3

Curso: Machine Learning

Sección: 1866

Docente: Diego Rojas Sihuay

Grupo: X

Integrantes:

Omar Acuña Villegas - u201613422

Axel Yamir Pariona Rojas - u202222148

Marcelo Paolo Murguia Lozano - u202013543

Noviembre 2025

ÍNDICE

Introducción:.....	3
Metodología:.....	3
2.1 Preparación del Dataset.....	3
2.2 Preprocesamiento y Entrenamiento del Modelo.....	4
2.3 Integración con el Robot NAO.....	4
2.4 Pruebas en el Simulador Choregraphe.....	4
Resultados:.....	5
3.1 Resultados del Entrenamiento.....	5
3.2 Evaluación del Modelo.....	6
3.3 Pruebas en el Simulador Choregraphe.....	6
3.4 Prueba en el NAO Físico.....	6
Conclusiones:.....	7
Anexos:.....	8

Introducción:

El presente proyecto tiene como objetivo el desarrollo e integración de un modelo de Machine Learning supervisado en el robot humanoide NAO, con el propósito de detectar golpes, o la ausencia de los mismos, y activar acciones físicas correspondientes. Este sistema fue diseñado para enseñar defensa personal mediante la interacción con el robot, simulando situaciones en las cuales el robot debe reaccionar ante un golpe inminente, ejecutando movimientos y acciones específicas.

El modelo de Machine Learning utilizado para la detección de golpes es un clasificador binario que emplea un dataset de imágenes con diferentes posturas y gestos de manos, clasificando entre "puño" (fist) y "no puño" (no_fist). Este modelo entrenado se integra con NAO, utilizando sus capacidades de visión por computadora y actuadores para realizar movimientos de defensa y reacciones vocales en función de la predicción del modelo.

El informe que sigue detalla el proceso completo de desarrollo, que incluye la preparación del dataset, el entrenamiento del modelo, la integración con NAO, y las pruebas realizadas en el simulador Choregraphe, con una futura implementación en el NAO físico. Además, se explicará la metodología utilizada, los resultados obtenidos y las conclusiones finales del trabajo.

Este sistema fue diseñado para enseñar defensa personal mediante la interacción con el robot, simulando situaciones en las cuales el robot debe reaccionar ante un golpe inminente, ejecutando movimientos y acciones específicas. Este enfoque no solo es útil para defensa personal, sino también en entornos educativos y de seguridad, donde los robots humanoides pueden servir como herramientas de aprendizaje y prevención.

Metodología:


El desarrollo del proyecto se divide en varias etapas clave, las cuales incluyen la preparación de los datos, el diseño y entrenamiento del modelo de Machine Learning, la integración con el robot NAO, y las pruebas realizadas. A continuación, se detalla cada uno de estos procesos.

2.1 Preparación del Dataset

El primer paso del proyecto fue la recopilación y preparación del dataset. Este dataset está compuesto por imágenes de diferentes posturas de las manos, como "puño" (fist), "cinco" (five), "ninguno" (none), "ok", "paz" (peace), "rojo" (rad), "recto" (straight), y "pulgar" (thumbs). Las imágenes fueron tomadas en diferentes condiciones de iluminación y ángulos para asegurar la diversidad en los datos.

El dataset contiene imágenes clasificadas en varias categorías, tales como fist y no_fist. A continuación, se muestran algunos ejemplos representativos del dataset utilizado.

Esta imagen pertenece a la carpeta fist



Esta imagen pertenece a las demás carpetas que no son fist



Para que el modelo fuera adecuado para clasificación binaria (fist vs. no_fist), se realizó un proceso de binarización, donde las imágenes fueron clasificadas únicamente en dos categorías: fist y no_fist. Este paso fue fundamental para alinear el dataset con los requisitos del proyecto y garantizar que el modelo pudiera predecir adecuadamente si hay un golpe o no.

2.2 Preprocesamiento y Entrenamiento del Modelo

El modelo utilizado en este proyecto es un clasificador binario basado en la arquitectura MobileNetV2, que es adecuada para tareas de clasificación de imágenes. Para su entrenamiento, se empleó un proceso de transfer learning, aprovechando el conocimiento previo de MobileNetV2 entrenado en un gran conjunto de datos como ImageNet.

Se utilizó la arquitectura MobileNetV2, que es eficiente y adecuada para tareas de clasificación de imágenes debido a su bajo requerimiento de recursos computacionales, lo

cual lo hace ideal para el entorno de un robot como NAO. Para mejorar la capacidad de generalización del modelo y evitar el sobreajuste, se utilizó la clase ImageDataGenerator de Keras, lo que permitió aplicar aumentos de datos como rotaciones y desplazamientos. El dataset se dividió en entrenamiento (70%), validación (15%) y prueba (15%) para evaluar el rendimiento del modelo en datos no vistos.

Durante el entrenamiento, se utilizó la función de pérdida `binary_crossentropy` y `accuracy` como métrica principal para evaluar el desempeño del modelo. También se emplearon callbacks como `ModelCheckpoint`, `EarlyStopping`, y `ReduceLROnPlateau` para optimizar el proceso de entrenamiento.

2.3 Integración con el Robot NAO

Una vez que el modelo fue entrenado y evaluado con un rendimiento satisfactorio, el siguiente paso fue integrarlo con el robot NAO. Para ello, se utilizaron los API de NAOqi, que permiten la interacción con las capacidades del robot como el movimiento y la síntesis de voz.

Los scripts de integración se encargan de realizar las siguientes tareas:


- **Conexión al robot NAO:** Se estableció una conexión entre el modelo y el robot NAO mediante las bibliotecas NAOqi. Esto permitió que el robot recibiera imágenes en tiempo real a través de su cámara, las procesara y realizara una predicción. Según el resultado de la predicción, el robot ejecutó acciones físicas (como posturas defensivas) o regresó a una postura neutral.
- **Procesamiento de imágenes:** El robot utiliza su cámara para capturar imágenes en tiempo real. Estas imágenes se preprocesan y se envían al modelo entrenado para que realice la predicción.
- **Reacciones del robot:** Según la predicción del modelo (`fist` o `no_fist`), el robot realiza una acción física: si detecta un golpe, ejecuta una postura defensiva (brazos recogidos y listos para defenderse); si no detecta un golpe, el robot regresa a una postura neutral.

2.4 Pruebas en el Simulador Choregraphe

El simulador Choregraphe fue utilizado para realizar pruebas iniciales del sistema antes de su implementación en el robot físico. En este simulador, se verificaron las funcionalidades de detección de golpes y la ejecución de las acciones físicas del robot. Se confirmaron las siguientes interacciones:

- El robot detectó correctamente los gestos de golpe y reaccionó de acuerdo a las predicciones del modelo.
- Las acciones físicas del robot, como las posturas defensivas y neutrales, se ejecutaron sin errores.
- La interacción de voz también funcionó correctamente, con el robot emitiendo mensajes como "¡Alerta! Estás demasiado cerca" o "No se detecta amenaza".

A continuación, se muestra una captura de pantalla del simulador con el robot realizando un movimiento de defensa tras detectar un golpe.



Resultados:

3.1 Resultados del Entrenamiento


Durante el proceso de entrenamiento, se entrenó un modelo basado en MobileNetV2 utilizando un conjunto de datos binarizado que clasifica entre dos categorías: fist (golpe) y no_fist (sin golpe). El modelo se entrenó durante 10 épocas y se utilizó un tamaño de lote de 32.


Las métricas de evaluación más importantes fueron:

- Precisión (Accuracy): Indicó el porcentaje de predicciones correctas realizadas por el modelo.
- Pérdida (Loss): Mide la diferencia entre las predicciones del modelo y los valores reales. Se utiliza para optimizar el modelo durante el entrenamiento.

Gráficas de desempeño:

A continuación se presentan las curvas de precisión y pérdida generadas durante el entrenamiento. Estas gráficas muestran cómo el modelo fue aprendiendo con el tiempo y proporcionan una indicación visual del progreso en la optimización.





Las gráficas de precisión y pérdida muestran lo siguiente:

- Curva de precisión: A medida que avanzaban las épocas de entrenamiento, la precisión del modelo aumentaba, indicando que el modelo se estaba ajustando bien a los datos.
- Curva de pérdida: La pérdida disminuyó gradualmente, lo que sugiere que el modelo estaba mejorando su capacidad para predecir correctamente los golpes y las posturas de "no golpe".

3.2 Evaluación del Modelo

El modelo fue evaluado utilizando el conjunto de validación, y los resultados fueron los siguientes:

- Precisión (Accuracy): 0.998

Esto indica que el modelo fue capaz de clasificar correctamente casi todas las imágenes del conjunto de validación. Complementariamente, el modelo obtuvo un F1-Score de 0.998, lo que demuestra un excelente equilibrio entre precisión y recall en la detección del gesto fist.

- Pérdida (Loss): 0.002

El valor de pérdida final fue muy bajo, lo que refleja que el modelo ajustó correctamente sus predicciones y aprendió a diferenciar de manera eficiente entre *fist* y *no_fist*. La pérdida disminuyó progresivamente durante el entrenamiento, demostrando una convergencia estable.


El F1-score es una métrica importante en clasificación binaria, especialmente cuando las clases están desbalanceadas. Un alto F1-score indica que el modelo tiene un buen equilibrio entre la precisión y la recuperación (recall).


3.3 Pruebas en el Simulador Choregraphe

Se realizaron pruebas exhaustivas en el simulador Choregraphe, donde el robot NAO ejecutó varias acciones en respuesta a la predicción del modelo. Durante estas pruebas, se verificaron los siguientes aspectos:

1. Detección de golpes: El robot detectó correctamente cuando se realizó un golpe y ejecutó la acción de defensa correspondiente (movimiento de brazos para simular una defensa).
2. No detección de golpes: Cuando no se detectó un golpe, el robot regresó a una postura neutral.

A continuación, se muestra una captura de pantalla del simulador Choregraphe, donde el robot reacciona a una predicción de "fist" (golpe) realizando una postura defensiva.





El robot también interactuó verbalmente, utilizando mensajes como "¡Alerta! Estás demasiado cerca" cuando detectaba un golpe, y "No se detecta amenaza" cuando no se detectaba un golpe. Este comportamiento se logró integrando las funcionalidades de síntesis de voz de NAO.


3.4 Prueba en el NAO Físico

Finalmente, se realizó la prueba del sistema en el robot NAO físico ubicado en el FabLab. Durante esta etapa, se verificó el funcionamiento del modelo en un entorno real, utilizando la cámara integrada del robot para capturar imágenes en tiempo real y procesarlas mediante el modelo entrenado.

Los resultados fueron satisfactorios:

- El robot logró detectar correctamente el gesto de “fist” (golpe) en múltiples intentos, incluso con variaciones leves en distancia, ángulo y iluminación.
- Al detectar un golpe, el robot ejecutó de manera inmediata la postura defensiva programada, levantando los brazos y adoptando una posición de protección.
- Cuando no se detectó un puño, el robot permaneció en su postura neutral sin realizar movimientos adicionales, demostrando estabilidad en la predicción y evitando falsas alarmas.

La interacción completa (captura → predicción → acción física) se realizó de forma automática y sin intervención manual, confirmando que el comportamiento observado en el simulador Choregraphe se replica de manera consistente en el robot físico. Estos resultados validan la integración entre el modelo de Machine Learning y el hardware del NAO, demostrando que el sistema funciona correctamente en un entorno real.



Conclusiones:

4.1 Logros y cumplimiento de objetivos

El proyecto ha sido un éxito en términos de los objetivos planteados, logrando integrar un modelo de Machine Learning supervisado para detectar golpes en un robot NAO y permitir que este reaccione de manera apropiada. A continuación, se detallan los logros clave:

1. Desarrollo del Modelo de Machine Learning:

Se entrenó un modelo binario utilizando MobileNetV2 para detectar si una imagen corresponde a un golpe (fist) o no (no_fist). El modelo fue entrenado y validado con un dataset de imágenes de gestos de manos, logrando un buen rendimiento en términos de precisión y pérdida.

Se implementaron técnicas de aumento de datos y transferencia de aprendizaje, lo que permitió que el modelo se ajustara bien a los datos disponibles y generalizara correctamente.

2. Integración con el Robot NAO:

El sistema se integró con el robot NAO, utilizando sus capacidades de visión y movimiento. El robot reaccionó correctamente a las predicciones del modelo, realizando acciones físicas como posturas defensivas o neutras.

La interacción automatizada entre el modelo y el robot, sin intervención manual, cumplió con los requisitos planteados en el enunciado del proyecto.

3. Pruebas en el Simulador Choregraphe:

Se realizaron pruebas exhaustivas en el simulador Choregraphe, donde el robot demostró su capacidad para detectar y reaccionar a los golpes de manera efectiva.

El simulador permitió verificar que el sistema funciona correctamente en un entorno controlado, lo que sugiere que el sistema funcionará de la misma manera en el robot físico.

4.2 Áreas de mejora y futuras extensiones

Aunque el proyecto ha sido exitoso, siempre hay espacio para mejorar. Algunas posibles áreas de mejora incluyen:

1. Mejorar la precisión del modelo:

Aunque el modelo alcanzó una buena precisión, siempre es posible mejorar el rendimiento mediante el ajuste de hiperparámetros, el uso de un mayor número de datos o el uso de arquitecturas más complejas. Una opción sería explorar técnicas de fine-tuning o usar redes más profundas si se dispone de más datos.

2. Optimización de la reacción del robot:

Actualmente, el robot reacciona a los golpes mediante posturas predefinidas. Se podría extender el sistema para que el robot también aprenda a diferenciar entre tipos de golpes o amenazas, y ejecute una variedad de respuestas más complejas (por ejemplo, movimientos de esquivas, paradas, o bloqueos específicos).

3. Mejoras en la interacción de voz:

El robot ya utiliza mensajes de voz como "¡Alerta! Estás demasiado cerca" o "No se detecta amenaza". Se podría mejorar esta funcionalidad añadiendo una mayor variedad de respuestas, incluyendo más frases interactivas o incluso la capacidad de simular una conversación sobre la situación de defensa personal.

4. Áreas de uso:

Este sistema tiene un gran potencial de expansión. Por ejemplo, podría ser adaptado para detectar otros tipos de interacciones o integrar otros sensores para mejorar la precisión. También sería interesante explorar el uso de redes neuronales más complejas o el uso de datos en 3D para mejorar el desempeño en escenarios más complejos.

4.3 Reflexión

Este proyecto nos ha permitido integrar conceptos avanzados de Machine Learning con la robótica, demostrando cómo las técnicas de visión por computadora y aprendizaje automático

pueden mejorar la interacción con robots humanoides en situaciones prácticas. La capacidad del robot NAO de reaccionar de forma autónoma ante amenazas como los golpes representa un avance significativo en la enseñanza de la defensa personal y en aplicaciones de seguridad. Este proyecto abre la puerta a futuras aplicaciones en áreas como la seguridad personal, la interacción en entornos educativos, y la robótica de asistencia.

Anexos:

- Enlace del video de ejecución del proyecto:
https://youtu.be/F_7UR1QY6-U
- Enlace del proyecto en Github:
<https://github.com/Axel-Pariona/PRACTICA-CALIFICADA-3---MACHINE-LEARNING>
- Enlace de la base de datos:
<https://www.kaggle.com/datasets/kritanjali/jain/gestures-hand>